

# **Autorregulación del flujo sanguíneo cerebral Regresión usando Support Vector Machine**

Ignacio Ibáñez Aliaga  
Joaquín Villagra Pacheco  
Universidad de Santiago de Chile

**Abstract.** Using SVR a regression model is obtained, with it it is possible to arrive at the modeling of the dynamic cerebral autoregulation and through the entry of a step or the fall of the PAM to be able to identify if a patient presents hypercapnia or a state of normocapnia. Two subjects were analyzed, obtaining regression models with correlations in test of 69.76% and 66.39% respectively.

Usando SVR se obtiene un modelo de regresión, con él es posible llegar al modelamiento de la autorregulación cerebral dinámica y por medio de la entrada de un escalón o la caída de la PAM poder identificar si un paciente presenta hipercapnia o un estado de normocapnia. Se analizan dos sujetos, obteniendo modelos de regresión con correlaciones en test de un 69,76% y 66,39% respectivamente.

**Keywords:** Autorregulación cerebral, Regression Support Vector Machine.

## **1 Introducción**

### **1.1 Contexto**

Entre el 15 y 25% del gasto cardíaco está dirigido al cerebro, con un flujo sanguíneo cerebral (FSC) de  $40 - 50 \text{ mL}/100\text{g}$  de tejido cerebral/min. El FSC está determinado por el consumo metabólico de oxígeno cerebral ( $CMRO_2$ ), influida por la autorregulación mediante la resistencia vascular cerebral (RVC), y por la presión de perfusión cerebral (PPC), que es la diferencia entre la PAM y la PIC[1].

El  $CMRO_2$  corresponde, en un 40%, al gasto energético basal (en su mayor parte para mantener el potencial de membrana, por lo que no es modificable por fármacos pero sí termosensible) y en un 60% al gasto energético funcional (no termosensible pero sí modificable por fármacos)[2].

El 90% de este  $CMRO_2$  corresponde al tejido neuronal y sólo un 10% al tejido de sostén o glía (el cual supone más del 50% del volumen encefálico). El  $CMRO_2$  se encuentra entre  $4 - 6 \text{ mL}/100\text{g}$  de tejido cerebral/min. Así, situaciones patológicas como la anemia o la hipoxia reducirán el contenido arterial de oxígeno, pudiendo determinar una entrega cerebral de oxígeno inadecuada[3].


La autorregulación cerebral se basa en la modificación de la RVC (vasodilatación o vasoconstricción) con el fin de mantener un FSC acorde a las necesidades metabólicas cerebrales de  $O_2$  de cada momento. Está determinada en gran parte por la presión arterial de dióxido de carbono ( $PaCO_2$ ), por la PAM y, en menor medida,

por la presión parcial arterial de oxígeno, la adenosina, el pH, entre otros. Así, cuando la  $PaCO_2$  cerebral es alta (mayor trabajo metabólico), la RVC cae (vasodilatación), aumentando el FSC y la entrega cerebral de oxígeno ( $CDO_2$ ).

Lo contrario ocurre cuando la  $PaCO_2$  disminuye (menor trabajo metabólico; vasoconstricción). Se estima que el FSC varía en un 4% por cada mmHg de  $CO_2$ , en normotensión. Con la PAM ocurre algo similar, regulando el FSC para proteger al tejido cerebral de caídas o alzas bruscas de presión que pudiesen comprometer la  $CDO_2$ . Sin embargo, estas autorregulaciones tienen límites por encima o por debajo de los cuales el FSC se torna absolutamente dependiente de la PAM[4].

Dentro de los estudios asociados, se le conoce como normocapnia al comportamiento normal de la respuesta autorregulatoria de un sujeto a una alteración en la PAM. En cambio, para una respuesta anómala, en donde no se alcanza una regulación ideal se le conoce como hipercapnia.


El objetivo de esta experiencia es elaborar un modelo de regresión, por medio de este llegar al modelamiento de la autorregulación cerebral dinámica. Luego aplicando como entrada un escalón o la caída de la PAM poder identificar si un sujeto presenta el problema de hipercapnia o un estado de normocapnia.



**Figura 1.1.2:** Representación de una arteria en estado de normocapnia versus hipercapnia

## 1.2 Conjunto de datos

Se disponibiliza un conjunto de datos, dos señales (separadas cada una en un archivo). Cada señal posee dos atributos, la Velocidad de flujo sanguíneo cerebral (VFSC) y la presión arterial media del sujeto en instantes de tiempo de 0.2 segundos durando cada señal 5 minutos.



**Figura 1.1.2:** Relación existente entre FSC y PAM [2]

### 1.3 Estado del arte

Se usaron Máquinas de Vector de Soporte (SVM) para modelar las influencias de  $PaCO_2$  en Autorregulación en dos condiciones diferentes: la línea de base y durante la respiración del 5% de  $CO_2$  en el aire, en un grupo de 16 sujetos sanos. Esta experimentación fue realizada utilizando modelos autorregresivos multivariados que proporcionaron una mejora sustancial en contraposición a los modelos de respuesta finita al impulso. Además, se comprobó que los modelos no lineales presentan mejor rendimiento para ambas estructuras de modelo analizadas. Los coeficientes de correlación para los modelos autorregresivos multivariados no lineales fueron  $0,71 \pm 0,11$  al inicio del estudio, alcanzando  $0.91 \pm 0.06$  durante 5% de  $CO_2$  [9].

## 2 Métodos y datos

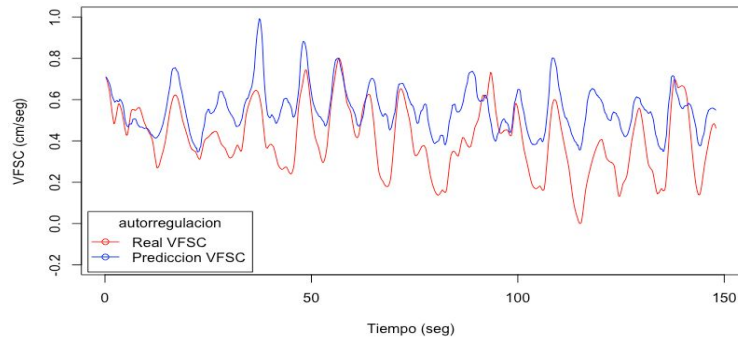
Tomando como base la literatura consultada, en conjunto con lo investigado y capturado en cátedra [5], se hace uso de SVM adaptada para regresión, más conocida como SVR, utilizando parámetros Gamma en el rango de  $[2^{-15}, 2^3]$ , nu entre  $[0.1; 0.9]$  y costo en el rango  $[2^{-5}, 2^{15}]$ , tal como es recomendado [6].

Estos parámetros han sido probados por medio de una validación cruzada balanceada en donde la mitad de la señal es usada para entrenar en modelo NFIR con retardos en el tiempo entre 3 y 8, es decir, se ejecuta una búsqueda de fuerza bruta variando los parámetros anteriormente descritos y los retardos en el tiempo de manera tal de encontrar el mejor modelo de regresión. Se genera una grilla de la combinatoria de todos los parámetros, el procesamiento por cada sujeto demoró aproximadamente 10 horas y media, ejecutando el proceso de forma paralelizada en un computador portátil de 8 núcleos de procesamiento, cada uno de ellos con frecuencia de 2.8 GHz.

Por medio del PAM se intenta predecir el VSFM con la mitad de la señal como entrenamiento y la otra como datos de prueba. Usando la medida de correlación de pearson se comparan las señales originales versus su correspondiente predecida, permitiendo identificar así el modelo que más aprendizaje obtuvo para cada individuo. A partir de los modelos que experimentaron mayor aprendizaje, se le aplica la entrada de un escalón unitario inverso [10] con el objetivo de identificar el estado de la respuesta autorregulatoria de los sujetos ante la caída en la presión, clasificando si se encuentra en estado de normocapnia o hipercapnia.

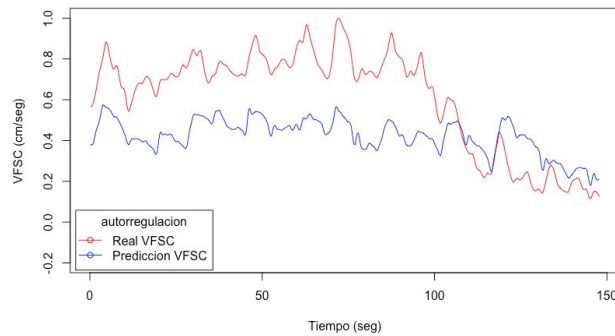
## 3 Resultados

Para el sujeto 1, se obtiene un modelo de regresión con los parámetros Gamma igual a  $3.906250e^{-3}$ , nu  $\frac{1}{2}$  y costo igual a 8192, entregando una correlación en test de un 69,76%.



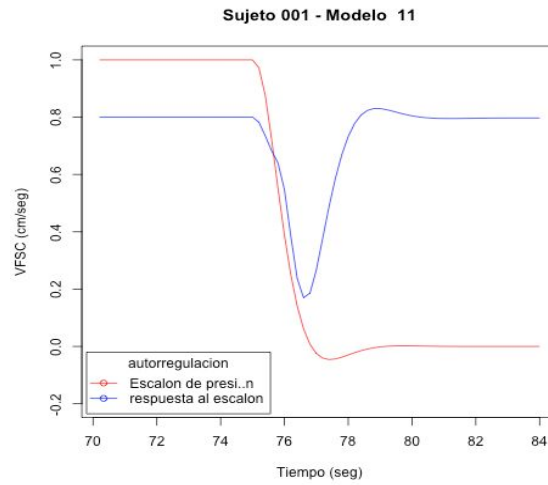
**Figura 3.1.1:** Correlación entre señal real y predecida por el mejor modelo (Sujeto 1)

Por otro lado, para el sujeto 2 se obtiene un modelo de regresión con Gamma igual a 0.015625, nu 0.9 y costo igual a 4, entregando una correlación en test de un 66,39%.



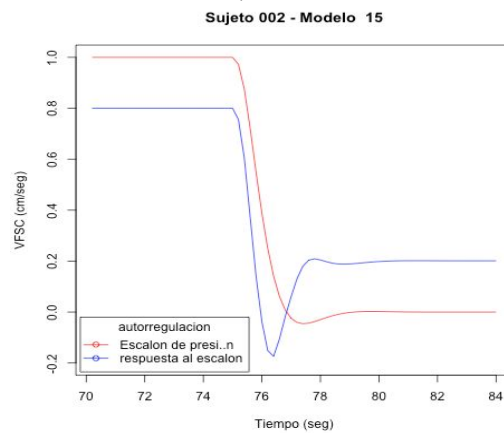
**Figura 3.1.1:** Correlación entre señal real y predecida por el mejor modelo (Sujeto 2)

En la respuesta al escalón experimentada por el sujeto 1, los parámetros utilizados por el modelo fueron Gamma igual a 0.0078125, nu igual a 0.5, costo igual a 2048 y una correlación de un 69,51%.



**Figura 3.1.3:** Respuesta ante caída de la PAM (Sujeto 1)

Por otro lado, la respuesta al escalón experimentada por el sujeto 2, los parámetros utilizados por el modelo fueron Gamma igual a 0.00390625, nu igual a 0.2, costo igual a 4096 y una correlación de un 67,08%.



**Figura 3.1.4:** Respuesta ante caída de la PAM (Sujeto 2)

## 4 Discusión

De acuerdo a los resultados expuestos, se evidencia claramente la diferencia en las respuestas autorregulatorias entre ambos sujetos, permitiendo indicar a priori que uno de ellos posee su comportamiento regulatorio desgastado. Ahora bien, identificar cuál de ellos es el paciente en normocapnia y cual es el que está en un estado de hipercapnia resulta sencillo a través de las Figuras 3.1.3 y 3.1.4. En la Figura 3.1.3 se observa una caída de la velocidad de flujo y una posterior recuperación de esta hasta el nivel original reportado, en cambio, en la Figura 3.1.4 se observa la bajada de la

velocidad de flujo y el posterior intento de subida, llegando hasta un cuarto de la velocidad que venía reportándose.

En base al comportamiento anterior y lo identificado en la literatura, resulta claro clasificar al sujeto 1 como aquel que posee un comportamiento regulatorio no deteriorado o normal (normocapnia). En cambio, el sujeto 2 pese al intento de regular la velocidad de flujo sanguíneo cerebral, no lo logra, ilustrando un caso de hipercapnia en donde existe un claro deterioro de la respuesta autorregulatoria.

## 5 Conclusiones

A partir de la literatura [9] y evidenciando empíricamente, la SVR otorga mejor correlación para aquellos sujetos con hipercapnia. Esto es ya que el método es capaz de adaptarse de buena manera al fenómeno fisiológico presente y representar un buen acercamiento a la respuesta autorregulatoria deteriorada de un individuo.

Esto es evidenciado en el hiper parámetro del costo dado que las mayores correlaciones son obtenidas en valores muy grandes en comparación al sujeto 2 que presenta un costo menor, es decir, se hace más fácil la adaptación al fenómeno para el sujeto 2.

Logra entenderse de manera práctica el efecto de la autorregulación tanto en sujetos con hipercapnia y normocapnia, pudiendo colocar en evidencia que a pesar de que un modelo presenta una mejor predicción en la señal no quiere decir que capte de mejor forma la respuesta fisiológica.

## 6 Referencias

1. Vavilala MS, Lee LA, Lam AM. Cerebral blood flow and vascular physiology. *Anesthesiol Clin North America*. 2002;20:247-264.
2. Jägersberg M, Schaller C, Boström J, Schatlo B, Kotowski M, Thees C. Simultaneous bedside assessment of global cerebral blood flow and effective cerebral perfusion pressure in patients with intracranial hypertension. *Neurocrit Care*. 2010;12:225-233.
3. Martin NA, Patwardhan RV, Alexander MJ, Africk CZ, Lee JH, Shalmon E, et al. Characterization of cerebral hemodynamic phases following severe head trauma: hypoperfusion, hyperemia, and vasospasm. *J Neurosurg*. 1997;87:9-19.
4. Frontera J, Ziai W, O'Phelan K, Leroux PD, Kirkpatrick PJ, Diringner MN, et al. Regional brain monitoring in the Neurocritical Care Unit. *Neurocrit Care*. 2015;22:348-359.
5. Chacón, M (2017) Taller de minería de datos avanzada, Capítulo 6: Regression Support Vector Machine.
6. Chih-Wei Hsu, Chih-Chung Chang, and Chih-Jen Lin (2003). A Practical Guide to Support Vector Classification. Departamento de Ciencias de la Computación e Ingeniería de la Información Universidad Nacional de Taiwán.

7. W. N. Street, O. L. Mangasarian, and W.H. Wolberg. An inductive learning approach to prognostic prediction. In A. Prieditis and S. Russell, editors Proceedings of the Twelfth International Conference on Machine Learning, pages 522-530, San Francisco, 1995. Morgan Kaufmann.
8. Yang J., Yao D., Zhan X., Zhan X. (2014) Predicting Disease Risks Using Feature Selection Based on Random Forest and Support Vector Machine. In: Basu M., Pan Y., Wang J. (eds) Bioinformatics Research and Applications. ISBRA 2014. Lecture Notes in Computer Science, vol 8492. Springer, Cham
9. Max Chacon, Claudio Araya, Ronney B. Panerai (2011) Non-linear multivariate modeling of cerebral hemodynamics with autoregressive Support Vector Machines. Department of Engineering Informatics, University of Santiago, Av. Ecuador 3659, Casilla 10233, Santiago, Chile
10. Felipe Bello (2017) Escalón unitario inverso en base a la investigación realizada por Claassen JA, Meel-van den Abeelen AS, Simpson DM, Panerai RB. "Transfer function analysis of dynamic cerebral autoregulation: A white paper from the International Cerebral Autoregulation Research Network".